# Diagnóstico de Calidad de Datos

Este documento presenta el diagnóstico realizado al DataFrame 'df_trabajo', generado a partir de una extracción de la BD sakila_espanol. El análisis evalúa la calidad de datos necesarios para responder a la pregunta de negocio mediante un checklist de 8 puntos, cuyos resultados se detallan a continuación:

## Volumen:

Se obtuvo de 4 columnas y 41 filas correspondientes los 41 días con operaciones registradas. En la Actividad 0 se reconcilio la base migrada conta el origen y no se encontraron diferencias. Con una query de consulta y un perfilado de datos al motor, se consiguieron los mismos resultados; por lo tanto, no fue necesario realizar trasformaciones en esta instancia.

## Tipos de Dato:

En este punto, la columna 'fecha' sufrió una transformación. Al haber llegado como tipo 'object' nos impedía los análisis cronológicos posteriores. Por ese motivo, se convirtió al tipo 'datetime' mediante 'pd_to_datetime()'.

## Faltantes:

Si bien en esta instancia se obtuvo un 0% de nulos en columnas, el faltante real se vio reflejado en la ausencia de días con registros de alquileres. De los 267 días esperados, solo 41 cuentan con registros. Optamos por construir la Serie Temporal sobre el calendario completo, tomando los ausentes como NaN y no como cero, ya que, al desconocer la información, asumir que no se efectuaron operaciones produciría un análisis erróneo.

## Duplicados:

No se obtuvo filas repetidas, permitiéndonos tomar la fecha como clave. Se obtuvo el mismo resultado tanto en el perfilado del conjunto de trabajo como del lado del motor. Por ello, no se efectuaron trasformaciones en este punto.

## Reglas de Negocio RN:

En ambas RN establecidas, donde el cumplimiento de: 'clientes activos' sea ≤ a los 'alquileres del día', y que no se obtengan valores negativos en: ingresos, alquileres y clientes activos; se registran 0 violaciones.

Aunque la regla del IQR no detectó atípicos, se identificaron dos observaciones: los primeros dias de cada bloque semanal, 5 martes con 8 a 33 registros, y el *ultimo* registro disponible, con una carga en lote de 182 alquileres.

Se decidió conservar los seis días, aunque se excluyeron de las comparaciones intersemanales del análisis posterior. No se consideraron errores; sin embargo, la brecha horaria de sus operaciones difiere de la observada en el resto de los días, por lo que no

resultan comparables. Incluirlos habría inducido una tendencia de decaimiento incongruente. Esta decisión quedó documentada en la actividad 2, celda 12, y en la actividad 3, celda 17, del Notebook.

## Variables Categóricas:

El conjunto no trajo columnas categóricas de texto, únicamente la fecha llego como tipo 'object' y la misma sufrió su correspondiente tratamiento, que al convertirse en tipo 'datetime' no presenta variantes en la escritura.

## Cardinalidad de Columnas:

La fecha presenta 41 filas con 41 valores distintos, ninguna columna numérica es constante, por lo que en este punto no hubo transformación alguna ya que todas las columnas aportan información.

## Período de Cobertura:

Se obtuvo desde el 24/05/2005 al 14/02/2006, con una cobertura operacional del 15,36% comprendiendo: 5 bloques de 8 días consecutivos con alquileres, separados por ventanas de 13 días sin datos, sufriendo un salto de 174 días sin registros hasta el día aislado del 14/02/06.

Esta brecha nos acota un análisis a gran escala, ya que cada bloque obtenido no alcanza para estudiar tendencias de estacionalidad anual y/o semestral, ni sostener afirmaciones.

Pero si nos proporciona períodos semanales en bloques, permitiéndonos analizar patrones semanales.

## Decisiones Tomadas:

El primer martes de cada bloque operacional obtenido, y el ultimo registro disponible (también martes), se clasificaron como 'días parciales'. Se conservaron porque representan datos reales proporcionados por el origen, pero se excluyeron de las inferencias sobre tendencias en análisis posteriores, debido a que no resultan comparables con los días completos. Esta decisión se documentó y justifico en la celda 12 del Notebook.

Las fechas obtenidas sin datos operacionales no se imputaron, ni se completaron con 0, ya que ese tratamiento habría atribuido información a operaciones que en verdad desconocemos el paradero del dato real.